

OMNI ORACLE · 研究简报

如何用 AI 提高宏观经济和趋势预测的准确性

证据、陷阱与一套可落地的架构 — 基于 Omni Oracle 平台与 2025—2026 文献

Presley Zhou · Omni Oracle · 2026 年 10 月

presleyzhou.github.io/omni-oracle

预测为什么难：三种误差来源

1

数据本身在动

官方数据发布滞后 1—3 个月，且不断修订（GDP 三次估计、就业年度基准修订）。模型看到的历史与当时可知的历史并不相同。

AI 对策 → 更快的数据：即时预测层

2

世界会换机制

2021 年通胀失控：模型几乎只在「大缓和」时期的数据上估计，供给冲击的机制在样本里被严重低估。

AI 对策 → 更宽的样本：TSFM 与文本层

3

人的先验决定结果

Stevanovic (2026): 60 岁以上、经历过 1970 年代的受访者更早上调通胀预期；「先验的来源比模型的复杂程度更重要」。

AI 对策 → 更多的视角：LLM 群体 + 市场

AI 在哪些环节已经被证明有效

任务	有效方法	证据强度	关键文献
GDP / 通胀即时预测	DFM + 随机森林 + TSFM 集成	★★★★★	Kant—Pick—Winter 2024; IMF WP/25/252; RBNZ TSFM 比较
通胀密度预测与风险	分位数回归森林 (QRF)	★★★★★	Lenza et al. 2025 EER; ECB 2026 博客
文本 → 经济指数	LLM 抽取新闻/财报/央行讲话	★★★★	Giannellis 2026 JoF; JKSU—CIS 2026
事件概率判断	LLM 预测者 + 人机混合	★★★★	ForecastBench 2026; Lu 2025
危机预警	有理论的指标 + ML 非线性	★★★★	Bluwstein et al. 2023 JIE; du Plessis & Fritsche 2025
趋势公司 / 股票排序	ML 因子 + 专利与文本嵌入	★★★★	Gu—Kelly—Xiu 2020; arXiv 2606.29290

来源：各行文献见对应页

Nowcasting：动态因子模型 + 随机森林 + 时序基础模型

1 DFM 是骨架

Giannone—Reichlin—Small 处理混频与 ragged edge，纽约联储沿用至今；每次发布后给出「新闻分解」——哪条数据把预测推动了多少。

2 随机森林通常最好

Kant, Pick & Winter (2024) 与 IMF WP/2025/252 的赛马：RF 在即时预测与短期预测上居首，DFM 在回溯上最佳——所以要集成，不是替换。

3 TSFM 零样本已可用

Chronos-2 (2025-10) 支持多变量与协变量；TimesFM 2.5 在 1000 亿时点上预训练。RBNZ 比较显示零样本 TSFM 在 GDP 即时预测上优于央行基准。

4 但嵌入空间非平稳

arXiv 2604.16428：TSFM 嵌入随机漂移；在金融序列上结果参差 (2511.18578)。结论仍是「作为第三个模型家族加入集成」。

即时预测栈 (M1)

DFM 即时预测

混频 · ragged edge · 新闻分解

随机森林 / GBT

非线性 · 替代数据

TSFM 零样本

Chronos-2 · TimesFM 2.5

BVAR 情景

条件路径 · 扇形图

让 LLM 读新闻、财报和央行讲话——再交给计量模型

1 GDP

JKSU-CIS (2026): LLM 把异质文本压成统一经济指数, LLM 增强模型「持续且显著」优于仅用结构化数据的基准。

2 通胀

Giannellis et al. (2026, J. Forecasting): 2020M1–2025M9 美欧月度样本, 所有 LLM 方案都显著改善传统模型。

3 央行实践

ECB 自 2022 年底把 QRF 纳入政策准备工具箱: 60 个变量、给出密度与风险信号; 2025 年二、四季度模型区间高于官方预测, 实际通胀高出 20bp——上行风险被提前捕捉。

4 原则

LLM 负责「读」, 计量模型负责「算」: 文本生成的是特征, 不是预测值。

+20 bp

2025Q2/Q4 实际通胀高于 ECB 官方预测 — QRF
已提前标出上行风险

ECB · 2026-04 博客

前视偏差：伪样本外表现好，真实时预测差

1 ChatMacro (SF Fed WP)

让 ChatGPT 实时预测美国通胀：真实样本外「大体不准且陈旧」，而伪样本外却与基准相当——训练语料已经「看过」答案。

2 Look-Ahead-Bench / Profit Mirage

arXiv 2601.13770 与 2510.07920：LLM 金融代理的回测收益在剔除前视信息后大幅缩水。


3 解法

① 时间一致的 LLM (2502.21206)；② 只用评分日之前发布的文本；③ 用 ALFRED vintage 回测——MACROCAST (2606.28670) 是首个 vintage 一致的 TSFM；④ 只在知识截止之后创建的问题上评分——Agentic Time Machine (2606.21013) 过滤截止日后的网页重建历史信息状态。



允许模型看到的一切都必须落在「预测发布」之前——用时间戳、数据 vintage 和知识截止日期来强制执行

LLM 判断事件概率：差距还有约一年



- 1 2026-01 排行榜
超级预测者仍居第一；Grok 4.20 与集成方案并列第二，领先 GPT-5、o3、Claude Sonnet 4.5。差距 0.017 Brier $\approx$ 一年的模型进步。
- 2 硅基群体
多模型集成有时已追平人类聚合——「accuracy-correlation effect」：多样性比单模型精度更重要 (Phil. Trans. R. Soc. B 2026)。
- 3 人机混合最强
带超级预测原则的 LLM 助手让人类准确率提升 23—43%。Lu (2025, 464 题)：前沿模型胜过人类大众，但仍明显落后专家组。

来源：ForecastBench (Wharton, 2026-02 版), arXiv 2409.19839 · Lu (2025), Evaluating LLMs on Real-World Forecasting Against Expert Forecasters, arXiv 2507.04562 · Phil. Trans. R. Soc. B 381 (2026), accuracy-correlation effect

模型 + 群体 + 市场：按样本外表现加权，并公开归因

1 理论

Timmermann (2006) 与 Ranjan—Gneiting：组合几乎总优于挑选单一最优；简单均值是难以击败的基准。

2 三类信号互补

模型（数据驱动）、预测者群体（判断）、预测市场价格（激励）。三者误差相关性低，正是集成收益的来源。

3 透明归因


每个预测都显示：模型贡献多少、群体多少、市场多少——用户能看到分歧，分歧本身就是信息。

4 反例：辩论式共识更差

2605.30802：独立投票 + 置信度加权 83.4% > 最佳单模型；让模型互相辩论反降至约 76%——自信的错误模型翻转了正确模型。集成要独立，不要开会。

5 Omni Oracle 实现

C2 集成引擎；AI 交易者与结算台按独立投票聚合，分歧 >25pp 的市场标为「有争议」不交易。



危机预警：把 AI 放在有理论的指标之上



1 收益率曲线

越平坦或倒挂，危机概率越高——即使危机之前没有衰退 (Bluwstein et al. 2023, JIE)。纽约联储 probit: $P = \Phi(-0.533 - 0.633 \times \text{利差})$ 。

2 信贷 + 曲线 + ML

Bluwstein 等用 ML 处理 17 国 140 年数据：信贷增长与收益率曲线是最强预测因子，非线性带来增益。du Plessis & Fritsche (2025) 用 13 种算法验证 147 年危机样本。

3 先规则，后模型

Sahm 规则、VIX、Baa 利差都有公开阈值；AI 的角色是在这些指标之上学非线性与交互，并给出可解释性。

趋势公司与股票：文本嵌入正在成为新的因子

0.86

年化 Sharpe: 10-K 嵌入 + 供应链传播因子
(2606.29290)

7.27%

年 FF5 alpha, 同一策略, S&P 500 2011—
2025

x2

Gu—Kelly—Xiu: 树与神经网络策略表现约为
回归的两倍

1

蓝本

Gu, Kelly & Xiu (2020, RFS): ML 的增益来自非线性交互; 主导信号仍是动量、流动性、波动率。

2

文本进入因子

10-K 嵌入沿供应链知识图谱传播 (2606.29290); LLM 过滤语义网络中的伪连边 (2604.19476); 结构化事件抽取而非纯嵌入 (2512.19484)。

3

专利与创新

Kogan et al. (2017) 市场反应法专利价值; 市场对专利文本反应不足 (Zheng 2025 CAR)——可利用的信号。

4

纪律

Welch—Goyal 式扩展窗口样本外; 与 FF5 / q 因子对比; 只用评分日前发布的文本。

能被评分的预测才会进步

1 Brier 分与校准曲线

对每个预测者、每个模型、每个集成公开记录；校准曲线揭示过度自信。

2 污染安全评分

AI 参与者只在其知识截止之后创建的问题上计分；UI 上永远显示截止日期徽章。


3 Alpha Score

arXiv 2605.00420：以提交时的市场中价为基准评分——链上市场是天然的未污染题库。

4 谨慎解读短期 PnL

六个前沿模型真钱交易 57 天全部亏损（Prediction Arena）；2026 世界杯 104 场，四个智能体无一打败博彩公司（2607.17765）。真实台账：入账时市场价的 Brier ≈ 0.1 （2026-10，42 道）——要击败的基准，每日更新。

一套可以今天开始搭的架构（Omni Oracle 演示实现）



↑ 信号自下而上流动；每一层都可独立评分

按「投入 × 影响」排序的七步

#	改进项	模块	投入	影响
1	AI 预测者基准 + 人/AI/集成 Brier 对比	C1/C2	中	★★★★★
2	TSFM (Chronos-2) 加入即时预测集成并归因	M1	中	★★★★★
3	AI 交易沙盒 vs LMSR 市场（自带密钥、模拟资金）	P/C5	中	★★★★★
4	M3 交互拓扑 + 历史种子验证	M3	中一大	★★★★★
5	相关市场语义聚类	P	小	★★★★
6	M2 记分卡文本情绪列（时点纪律）	M2	小一中	★★★★
7	全体 AI 参与者的污染安全评分规则	C3	小	★★★★（可信度）

前三项可在 90 天内以演示形式上线；第 7 项决定平台可信度，建议与第 1 项同步。

来源：Omni Oracle RESEARCH-UPDATES.md §Priority order

五条原则，一条底线

- 1 更快的数据 + 更宽的样本 + 更多的视角——对应三种误差来源
- 2 LLM 负责读，计量模型负责算；文本生成特征，不生成预测值
- 3 集成而非替换：模型 + 群体 + 市场，按样本外表现加权并公开归因
- 4 时间纪律高于算法：时间戳、数据 vintage、知识截止后计分
- 5 先规则后模型：危机预警建立在有理论的指标之上

底线

底线：LLM 直接做多元数值预测仍弱于线性回归；TSFM 嵌入非平稳；AI 代理真钱交易 57 天全部亏损。AI 提高的是流程的准确性，不是先知的能力。

参考文献与数据来源

- Stevanovic, D. (2026). Who Saw It Coming? Historical Experience and the 2021 Inflation Forecast Failure. arXiv 2604.14467.
- Giannellis et al. (2026). Inflation Forecasting With Large Language Models. Journal of Forecasting. doi 10.1002/for.70139.
- Alam et al. (2026). ChatMacro: Evaluating Inflation Forecasts of Generative AI. FRB San Francisco WP.
- ECB Blog (2026-04-21). Navigating uncertain times with the help of AI. Lenza et al. (2025), EER 178.
- JKUSU-CIS (2026). LLMs for unstructured economic data processing: GDP forecasting. doi 10.1007/s44443-026-00788-2.
- Kant, Pick & Winter (2024), AStA; IMF WP/2025/252 — ML nowcasting horseraces.
- Chronos-2 (Amazon, 2025-10); TimesFM 2.5 (Google); MDPI MAKE 7(4):135 — RBNZ TSFM 比较; arXiv 2604.16428; 2511.18578.
- ForecastBench (Wharton, 2026-02; arXiv 2409.19839); Lu (2025) arXiv 2507.04562; Phil. Trans. R. Soc. B 381 (2026).
- Look-Ahead-Bench arXiv 2601.13770; Profit Mirage 2510.07920; Chronologically Consistent LLMs 2502.21206; Agentic Time Machine 2606.21013; MACROCAST 2606.28670.
- Bluwstein, Buckmann, Joseph, Kapadia & Sımsık (2023), JIE; du Plessis & Fritsche (2025), J. Forecasting; Estrella & Trubin (2006); Sahm (2019).
- Gu, Kelly & Xiu (2020), RFS; arXiv 2606.29290; 2604.19476; 2512.19484; Kogan et al. (2017), QJE.
- Alpha Score arXiv 2605.00420; Prediction Arena arXiv 2604.07355; WC2026-Agents arXiv 2607.17765; Multi-agent oracles arXiv 2605.30802.
- Timmermann (2006); Ranjan & Gneiting (2010); Gneiting & Raftery (2007).
- Omni Oracle: github.com/presleyzhou/omni-oracle — DESIGN.md, RESEARCH-UPDATES.md, data/live.json.