

如何用 AI 提高宏观经济和趋势预测的准确性

证据、陷阱与一套可落地的架构 — 基于 Omni Oracle 平台与 2025–2026 文献

Presley Zhou · Omni Oracle · 2026 年 10 月 · presleyzhou.github.io/omni-oracle

如何使用

- 本讲义与幻灯片逐页对应 ("第 N 页" = 幻灯片页码)，共 15 页，建议总时长约 32 分钟。
- 每页包含：幻灯片要点、讲稿（对听众说的话，可直接照读或改写）、过渡语、可能的提问与建议回答、资料来源。
- 讲稿全文同时写入了 PPTX 的演讲者备注。

目录

第 1 页	封面	1 分钟
第 2 页	预测为什么难：三种误差来源	2.5 分钟
第 3 页	AI 在哪些环节已经被证明有效	2 分钟
第 4 页	Nowcasting：动态因子模型 + 随机森林 + 时序基础模型	3 分钟
第 5 页	让 LLM 读新闻、财报和央行讲话——再交给计量模型	3 分钟
第 6 页	前视偏差：伪样本外表现好，真实时预测差	3 分钟
第 7 页	LLM 判断事件概率：差距还有约一年	2.5 分钟
第 8 页	模型 + 群体 + 市场：按样本外表现加权，并公开归因	2 分钟
第 9 页	危机预警：把 AI 放在有理论的指标之上	3 分钟
第 10 页	趋势公司与股票：文本嵌入正在成为新的因子	2.5 分钟
第 11 页	能被评分的预测才会进步	2 分钟
第 12 页	一套可以今天开始搭的架构（Omni Oracle 演示实现）	2 分钟
第 13 页	按「投入 × 影响」排序的七步	1.5 分钟
第 14 页	五条原则，一条底线	2 分钟
第 15 页	参考文献与数据来源	—

第 1 页 · 封面

讲稿

各位好。今天这半个小时我想回答一个很具体的问题：人工智能到底能不能让宏观经济预测和趋势预测更准——如果能，准在哪里、怎么做到、又有哪些地方它其实做不到。

我不打算讲「AI 将改变一切」这类判断。今天所有结论都来自两类材料：一是 2025 到 2026 年发表的同行评审论文和央行工作论文，二是我们自己搭的开源演示平台 Omni Oracle 上跑出来的真实数据。每一页右下角都有出处，欢迎会后查证。

结构是这样的：先讲预测为什么难，然后分四层讲 AI 在哪里有效，中间会专门停下来讲一个最大的陷阱，接着看两个应用——危机预警和趋势预测，最后是评分、架构和路线图。

过渡语

我们从一个反直觉的事实开始：过去五年最大的预测失败，问题不在算法。

第 2 页 · 预测为什么难：三种误差来源

幻灯片要点

- **数据本身在动** — 官方数据发布滞后 1—3 个月，且不断修订（GDP 三次估计、就业年度基准修订）。模型看到的历史与当时可知的历史并不相同。
- **世界会换机制** — 2021 年通胀失控：模型几乎只在「大缓和」时期的数据上估计，供给冲击的机制在样本里被严重低估。
- **人的先验决定结果** — Stevanovic (2026)：60 岁以上、经历过 1970 年代的受访者更早上调通胀预期；「先验的来源比模型的复杂程度更重要」。
- *AI 对策* → *更快的数据：即时预测层*
- *AI 对策* → *更宽的样本：TSFM 与文本层*
- *AI 对策* → *更多的视角：LLM 群体 + 市场*

讲稿

先问一个问题：2021 年通胀从 1.4% 冲到 7%，几乎所有机构都没预测到。是模型太简单吗？今年四月 Stevanovic 的论文给出了一个很干净的答案：不是函数形式错了，是样本构成错了。这些模型几乎只在 1985 年之后「大缓和」时期的数据上估计，那个样本里几乎没有供给冲击。你用一段没有供给冲击的历史去训练，模型自然学不到供给冲击。

这就是第一种误差来源——世界会换机制。第二种来源更基础：数据本身在动。GDP 要发布三次估计，就业数据每年做基准修订，CPI 权重每年调整。今天模型看到的「2024 年数据」和 2024 年当时能看到的数据不是同一组数字。如果回测时用了修订后的数据，你就是在用未来的信息预测过去——这个问题我们在第六页会专门展开。

第三种来源最有意思：人的先验。Stevanovic 用 SPF 专业预测者的微观数据发现，60 岁以上、职业生涯经历过 1970 年代大通胀的预测者，从 2021 年初就开始上调通胀预期，而年轻的预测者一直锚定在 2%。他的原话是：「先验的来源，比模型的复杂程度更重要。」

这三条给了 AI 一个非常明确的任务清单：数据要更快、更接近实时；样本要更宽，能覆盖模型没见过的机制；视角要更多元，不能只有一种先验。接下来的四层，每一层都在解决其中一条。

过渡语

在进入具体方法之前，先给大家一张地图，看看哪些地方 AI 已经被证明有效。

可能的提问

问：能不能干脆用 1970 年代的数据重新训练？

答：Stevanovic 确实测试了三种修正：截距修正、加入 1970 年代数据重估、以及核加权估计——三种都显著改善了 2021 年的预测。但注意他的结论：起作用的是「先验的来源」，也就是你允许模型看

到什么样的历史，而不是换一个更复杂的模型。

问：数据修订真的会影响结论吗？

答：会。美国 GDP 初值与终值的平均修正幅度在 1 个百分点上下，足以改变「衰退还是不衰退」的判断。所以正规的回测必须用 ALFRED 这类保存了每个时点原始发布值的数据库。

资料来源

- Stevanovic (2026), Who Saw It Coming? Historical Experience and the 2021 Inflation Forecast Failure, arXiv 2604.14467
- Giannone, Reichlin & Small (2008), JME — nowcasting 与 ragged edge

第 3 页 · AI 在哪些环节已经被证明有效

幻灯片要点

任务	有效方法	证据强度	关键文献
GDP / 通胀即时预测	DFM + 随机森林 + TSFM 集成	★★★★	Kant—Pick—Winter 2024; IMF WP/25/252; RBNZ TSFM 比较
通胀密度预测与风险	分位数回归森林 (QRF)	★★★★	Lenza et al. 2025 EER; ECB 2026 博客
文本 → 经济指数	LLM 抽取新闻/财报/央行讲话	★★★	Giannellis 2026 JoF; JKSU—CIS 2026
事件概率判断	LLM 预测者 + 人机混合	★★★	ForecastBench 2026; Lu 2025
危机预警	有理论的指标 + ML 非线性	★★★	Bluwstein et al. 2023 JIE; du Plessis & Fritsche 2025
趋势公司 / 股票排序	ML 因子 + 专利与文本嵌入	★★★	Gu—Kelly—Xiu 2020; arXiv 2606.29290

讲稿

这张表是今天的目录，也是一张证据地图。左边是六类预测任务，中间是已经被验证有效的方法，星级是我对证据强度的判断——四星意味着有多个独立团队、在真实样本外得到一致结果；三星意味着证据很强，但样本还短或者仍有争议。

请大家注意两件事。第一，前两行——即时预测和通胀密度预测——是四星，而且方法都是「经典计量 + 机器学习」的组合，不是大语言模型。第二，整张表里没有一行写着「让 LLM 直接报一个数字」。这不是疏漏。今天你会看到，LLM 直接做数值预测的证据要么很弱，要么受到严重的数据污染质疑。

LLM 真正有效的位置在第三、四行：把文本变成可计算的信号，以及作为一个「预测者」参与概率判断。危机预警和股票排序则是 AI 与经典理论结合的领域。

过渡语

我们从最成熟的一层开始：即时预测。

可能的提问

问：星级是主观的吗？

答：是我的判断，但依据是可复现的：四星对应至少两个独立研究团队、样本外评估、并且有机构实际使用（比如纽约联储的 DFM、欧央行的 QRF）。

资料来源

- 各行文献见对应页

第 4 页 · Nowcasting：动态因子模型 + 随机森林 + 时序基础模型

幻灯片要点

- **DFM 是骨架** — Giannone—Reichlin—Small 处理混频与 ragged edge，纽约联储沿用至今；每次发布后给出「新闻分解」——哪条数据把预测推动了多少。
- **随机森林通常最好** — Kant, Pick & Winter (2024) 与 IMF WP/2025/252 的赛马：RF 在即时预测与短期预测上居首，DFM 在回溯上最佳——所以要集成，不是替换。
- **TSFM 零样本已可用** — Chronos-2 (2025-10) 支持多变量与协变量；TimesFM 2.5 在 1000 亿时点上预训练。RBNZ 比较显示零样本 TSFM 在 GDP 即时预测上优于央行基准。
- **但嵌入空间非平稳** — arXiv 2604.16428：TSFM 嵌入随机漂移；在金融序列上结果参差 (2511.18578)。结论仍是「作为第三个模型家族加入集成」。

讲稿

即时预测解决的是「数据滞后」问题。GDP 是季度数据，发布还要等一个月；但每周都有新的就业、零售、PMI 数据出来。Nowcasting 的任务就是把这些高频、不整齐的数据拼成一个对当季 GDP 的实时估计。

骨架是动态因子模型，Giannone、Reichlin 和 Small 2008 年的框架，纽约联储至今在用。它有两个别的方法很难替代的能力：处理混频数据和「不齐的边界」——就是有些指标已经出到 9 月、有些还停在 7 月的情况；以及给出「新闻分解」，告诉你这次预测变化中，有多少来自昨天的就业数据、多少来自 PMI。这对政策讨论非常有价值。

机器学习加在骨架上。Kant、Pick 和 Winter 2024 年，以及 IMF 2025 年的工作论文做了系统的赛马，结论一致：随机森林在即时预测和短期预测上通常最好，因为它抓住了非线性和变量之间的交互；但在回溯上 DFM 仍然最佳。所以正确的结论是「集成」，不是「替换」。

2025 年 10 月之后出现了第三个模型家族：时序基础模型。Amazon 的 Chronos-2 支持多变量和协变量，Google 的 TimesFM 2.5 在一千亿个时点上预训练。它们最大的特点是零样本——不需要在你的数据上训练。新西兰储备银行做的比较显示，零样本 TSFM 在 GDP 即时预测上打败了央行自己的基准模型。

但要诚实地说第四点：今年四月的一篇论文发现 TSFM 的内部表示会随经济机制漂移，另一篇在金融序列上得到参差的结果。所以我们的建议是：把 TSFM 当作集成里的第三个家族加进来，并公开每一层的实时记录，让数据决定权重。

过渡语

即时预测用的还是数值数据。下一层，我们把新闻和财报也变成数据。

可能的提问

问：随机森林能解释吗？

答：可以做变量重要性和 SHAP 分解，但不如 DFM 的新闻分解直观。这也是为什么我们保留 DFM 作为骨架——它负责解释，RF 负责精度。

问：TSFM 需要多少数据？

答：零样本模式下不需要训练数据，只需要历史序列作为上下文。这恰恰是它对宏观数据有吸引力的原因：宏观数据太短，训练不起深度模型。

资料来源

- Giannone, Reichlin & Small (2008)
- Kant, Pick & Winter (2024), AStA; IMF WP/2025/252
- MDPI MAKE 7(4):135 — RBNZ TSFM 比较
- arXiv 2604.16428; arXiv 2511.18578

第 5 页 · 让 LLM 读新闻、财报和央行讲话——再交给计量模型

幻灯片要点

- **GDP** — JKSU-CIS (2026): LLM 把异质文本压成统一经济指数, LLM 增强模型「持续且显著」优于仅用结构化数据的基准。
- **通胀** — Giannellis et al. (2026, J. Forecasting): 2020M1–2025M9 美欧月度样本, 所有 LLM 方案都显著改善传统模型。
- **央行实践** — ECB 自 2022 年底把 QRF 纳入政策准备工具箱: 60 个变量、给出密度与风险信号; 2025 年二、四季度模型区间高于官方预测, 实际通胀高出 20bp——上行风险被提前捕捉。
- **原则** — LLM 负责「读」, 计量模型负责「算」: 文本生成的是特征, 不是预测值。
- **+20 bp** 2025Q2/Q4 实际通胀高于 ECB 官方预测 — QRF 已提前标出上行风险

讲稿

第二层解决「信息面太窄」的问题。传统面板里只有几百个数值序列, 但央行讲话、财报电话会、新闻里有大量领先信息——而且往往比数据早几周。问题是怎么把文本变成模型能用的东西。

2026 年有两篇论文分别在 GDP 和通胀上给出了答案。一篇提出用大语言模型把异质的文本来源压缩成统一的经济指数, 再喂给预测模型, 结果是 LLM 增强模型「持续且显著」优于只用结构化数据的基准。另一篇 Giannellis 等人用 2020 年到 2025 年 9 月的美国和欧元区月度数据, 发现所有 LLM 方案都显著改善了传统通胀模型。

机构层面的最佳实践来自欧央行。他们从 2022 年底就把分位数回归森林——QRF——纳入货币政策准备的工具箱。它吃 60 个变量, 输出的不是一个点, 而是一个分布和风险信号。2025 年二季度和四季度, QRF 的区间整体高于欧央行官方预测, 后来实际通胀确实高出了 20 个基点。也就是说, 上行风险被提前标了出来。右边这个数字就是这件事。

请记住这一页的原则: LLM 负责「读」, 计量模型负责「算」。文本生成的是特征, 不是预测值。一旦你让 LLM 直接报数字, 就会掉进下一页的陷阱。

过渡语

说到陷阱——这是今天最重要的一页。

可能的提问

问: QRF 和普通随机森林有什么区别?

答: 普通随机森林输出条件均值; QRF 保留每个叶节点的全部观测, 可以输出任意分位数, 也就是整个条件分布。对央行来说, 风险区间比点预测更有用。

问: 文本层需要多少算力?

答：推理阶段很轻：每天几千篇文章的嵌入或摘要，一台普通 GPU 或 API 调用即可。真正的成本在数据治理——时间戳、去重、版权。

资料来源

- JKSU-CIS (2026), doi 10.1007/s44443-026-00788-2
- Giannellis et al. (2026), Journal of Forecasting, doi 10.1002/for.70139
- ECB Blog, 2026-04-21, Navigating uncertain times with AI; Lenza et al. (2025) EER 178

第 6 页 · 前视偏差：伪样本外表现好，真实时预测差

幻灯片要点

- **ChatMacro (SF Fed WP)** — 让 ChatGPT 实时预测美国通胀：真实样本外「大体不准且陈旧」，而伪样本外却与基准相当——训练语料已经「看过」答案。
- **Look-Ahead-Bench / Profit Mirage** — arXiv 2601.13770 与 2510.07920：LLM 金融代理的回测收益在剔除前视信息后大幅缩水。
- **解法** — ① 时间一致的 LLM (2502.21206)；② 只用评分日之前发布的文本；③ 用 ALFRED vintage 回测——MACROCAST (2606.28670) 是首个 vintage 一致的 TSFM；④ 只在知识截止之后创建的问题上评分——Agentic Time Machine (2606.21013) 过滤截止日后的网页重建历史信息状态。
- 时间线：训练截止 → 文本可见窗口 → 预测发布 → 结果揭晓 → 评分

讲稿

如果今天只记住一页，请记住这一页。旧金山联储的 ChatMacro 论文做了一个很简单的实验：让 ChatGPT 预测美国通胀。在「伪样本外」——也就是问它已经过去的时期——它的表现和专业预测者调查差不多。但当研究者在真实时间里、每个月实时去问它，预测「大体不准确，而且陈旧」。同一个模型，两种结果。原因很简单：训练语料里已经有了答案。

金融领域把这个现象叫「利润幻影」。Look-Ahead-Bench 和 Profit Mirage 两篇论文系统地测量了它：LLM 金融代理漂亮的回测收益，在剔除前视信息之后大幅缩水。这不是模型作弊，是评估方法在作弊。

怎么解？四条，全部是工程纪律，不是算法。第一，用时间一致的模型——2025 年有工作专门训练只见过某个日期之前语料的 LLM。第二，给每一段文本打时间戳，只用评分日之前发布的内容。第三，回测用 ALFRED 数据 vintage，也就是当时实际发布的数字——今年六月的 MACROCAST 把这件事做进了模型本身，是第一个完全排除修订偏差的时序基础模型。第四，评估 AI 预测者时，只用在它知识截止日期之后创建的问题——Agentic Time Machine 走得更远：它把截止日期之后的网页全部过滤掉，重建当时的信息状态，离线得分与实时排行榜高度相关。

下面这条时间线就是规矩：训练截止、文本可见窗口，都必须落在「预测发布」这个点之前；结果揭晓和评分在之后。任何跨过这条线的信息，都会让你的准确率变成幻觉。在 Omni Oracle 里，我们把这条规矩做进了产品：任何 LLM 输出旁边都显示知识截止日期。

过渡语

有了这条纪律，我们才能公平地讨论下一个问题：LLM 作为预测者到底有多准。

可能的提问

问：用最新模型是不是就没有这个问题？

答：恰恰相反。模型越新，训练截止越晚，「伪样本外」的窗口就越大，问题越隐蔽。唯一的解法是在知识截止之后的问题上评估。

问：ALFRED 是什么？

答：圣路易斯联储维护的数据库，保存了每个经济序列在每个历史时点的原始发布值。用它回测才能保证模型只看到当时可知的数字。

资料来源

- Alam et al. (2026), ChatMacro, SF Fed WP 2026-xx ([ideas.repec.org fedfwp/102407](https://ideas.repec.org/fedfwp/102407))
- Look-Ahead-Bench arXiv 2601.13770; Profit Mirage arXiv 2510.07920
- Chronologically Consistent LLMs arXiv 2502.21206

第 7 页 · LLM 判断事件概率：差距还有约一年

幻灯片要点

- **2026-01 排行榜** — 超级预测者仍居第一；Grok 4.20 与集成方案并列第二，领先 GPT-5、o3、Claude Sonnet 4.5。差距 0.017 Brier $\approx$ 一年的模型进步。
- **硅基群体** — 多模型集成有时已追平人类聚合——「accuracy–correlation effect」：多样性比单模型精度更重要 (Phil. Trans. R. Soc. B 2026)。
- **人机混合最强** — 带超级预测原则的 LLM 助手让人类准确率提升 23–43%。Lu (2025, 464 题)：前沿模型胜过人类大众，但仍明显落后专家组。
- **图表：ForecastBench Brier 分（越低越好）** — 超级预测者 0.096，Claude 3.5 Sonnet 0.122，GPT-4o 0.133

讲稿

第三层，我们把 LLM 当作一个预测者，而不是数据处理器。衡量它的标准和衡量人一样：Brier 分——预测概率与实际结果之差的平方，越低越好。

ForecastBench 是目前最严格的基准，由沃顿的团队维护。它的特点是问题全部关于未来，模型和人类回答同一批问题，所以不存在前视问题。左边的图是它的一组结果：超级预测者 0.096，Claude 3.5 Sonnet 0.122，GPT-4o 0.133。2026 年 1 月的排行榜上，超级预测者仍然第一，xAI 的 Grok 4.20 和一个集成方案并列第二，领先 GPT-5、o3 和 Claude Sonnet 4.5。领先幅度是 0.017 个 Brier 分——按过去一年的进步速度，大约相当于一年的差距。

第二个发现来自《皇家学会哲学汇刊》今年的一篇文章：多个不同模型的集成，有时已经追平人类群体的聚合预测。作者称之为「准确率—相关性效应」——模型之间的多样性，比单个模型的精度更重要。这和人类群体智慧的文献完全一致。

第三个发现最实用：人机混合最强。给人类预测者配一个遵循超级预测原则的 LLM 助手——提醒基准率、参考类别、范围敏感性——人类的准确率提升 23% 到 43%。Lu 2025 年用 464 道 Metaculus 题目也验证了排序：前沿模型已经胜过普通人群，但仍明显落后专家组。

过渡语

既然模型、人群、专家各有所长，自然的问题是：怎么把它们合起来？

可能的提问

问：Brier 分 0.017 的差距大吗？

答：如果一个预测者对所有问题都答 50%，Brier 分是 0.25。0.017 相当于从「大众水平」到「超级预测者」差距的大约五分之一。不小，但正在快速缩小。

问：为什么排行榜上有集成方案？

答：ForecastBench 允许提交任何系统。集成方案通常是多个模型的加权平均，再用人群预测做校正——正是下一页要讲的思路。

资料来源

- ForecastBench (Wharton, 2026-02 版), arXiv 2409.19839
- Lu (2025), Evaluating LLMs on Real-World Forecasting Against Expert Forecasters, arXiv 2507.04562
- Phil. Trans. R. Soc. B 381 (2026), accuracy—correlation effect

第 8 页 · 模型 + 群体 + 市场：按样本外表现加权，并公开归因

幻灯片要点

- **理论** — Timmermann (2006) 与 Ranjan—Gneiting：组合几乎总优于挑选单一最优；简单均值是难以击败的基准。
- **三类信号互补** — 模型（数据驱动）、预测者群体（判断）、预测市场价格（激励）。三者误差相关性低，正是集成收益的来源。
- **透明归因** — 每个预测都显示：模型贡献多少、群体多少、市场多少——用户能看到分歧，分歧本身就是信息。
- **反例：辩论式共识更差** — 2605.30802：独立投票 + 置信度加权 83.4% > 最佳单模型；让模型互相辩论反降至约 76%——自信的错误模型翻转了正确模型。集成要独立，不要开会。
- **Omni Oracle 实现** — C2 集成引擎；AI 交易者与结算台按独立投票聚合，分歧 >25pp 的市场标为「有争议」不交易。
- **集成权重示例**：DFM 即时预测 30%，随机森林 24%，TSFM (Chronos-2) 10%，BVAR 情景 12%，群体（锦标赛）13%，市场价格 11%

讲稿

第四层是集成。预测组合的文献有四十年历史，结论非常稳定：Timmermann 2006 年的综述、Ranjan 和 Gneiting 2010 年的工作都指出，组合几乎总是优于挑选单一最优模型，而且简单的等权平均是一个很难击败的基准。

真正的增益来自误差不相关的信号。我们有三类：模型，由数据驱动；预测者群体，代表人的判断；预测市场价格，背后是真金白银的激励。这三者犯的错误相关性很低——模型不会因为舆论恐慌而偏移，市场不会因为数据修订而失真——所以合在一起收益最大。

这里有一个 2026 年的反例值得记住。多智能体预言机的论文比较了两种聚合方式：让多个模型各自独立回答再按置信度加权投票，准确率 83.4%，高于最佳单模型；让模型互相辩论达成共识，反而降到 76% 左右——作者的解释是「自信的错误模型翻转了正确的模型」。所以集成要独立，不要开会。

产品层面有一个关键决策：归因透明。不要只给用户一个数字，要告诉他这个数字里模型占多少、群体占多少、市场占多少。当三者分歧很大时，分歧本身就是最重要的信息。右边是 Omni Oracle 设计文档里的示例权重——注意「示例」两个字，实际权重必须来自滚动的样本外表现，而不是拍脑袋。

过渡语

前面讲的都是「预测一个数」。接下来两个应用，一个是预测危机，一个是预测公司。

可能的提问

问：等权平均真的那么难击败吗？

答：在样本外，是的。原因是最优权重本身需要估计，估计误差常常抵消了最优权重的理论收益。这就是所谓的「预测组合之谜」。所以我们建议从等权开始，只有在有足够长记录时才偏离。

资料来源

- Timmermann (2006), Forecast Combinations, Handbook of Economic Forecasting
- Ranjan & Gneiting (2010), JRSS-B
- Omni Oracle DESIGN.md §C2

第 9 页 · 危机预警：把 AI 放在有理论的指标之上

幻灯片要点

- **收益率曲线** — 越平坦或倒挂，危机概率越高——即使危机之前没有衰退 (Bluwstein et al. 2023, JIE)。纽约联储 probit: $P = \Phi(-0.533 - 0.633 \times \text{利差})$ 。
- **信贷 + 曲线 + ML** — Bluwstein 等用 ML 处理 17 国 140 年数据：信贷增长与收益率曲线是最强预测因子，非线性带来增益。du Plessis & Fritsche (2025) 用 13 种算法验证 147 年危机样本。
- **先规则，后模型** — Sahm 规则、VIX、Baa 利差都有公开阈值；AI 的角色是在这些指标之上学非线性与交互，并给出可解释性。
- **图表：美国 10Y - 3M 国债利差 24 个月月均值** (Omni Oracle 每日快照，美国财政部数据)

讲稿

危机预警是 AI 最容易过拟合的领域，原因很简单：危机太少了。美国自 1970 年以来只有七次衰退。用几百个特征去拟合七个事件，几乎必然过拟合。所以这一页的标题是「把 AI 放在有理论的指标之上」，顺序不能反。

第一个指标是收益率曲线。Bluwstein 等人 2023 年在《国际经济学杂志》用 17 个国家 140 年的数据发现：曲线越平坦或越倒挂，危机概率越高——而且这对没有衰退在前的金融危机同样成立。纽约联储有一个用了二十年的 probit 公式，把 10 年减 3 个月的利差直接映射成 12 个月内衰退的概率。

机器学习的位置在哪里？Bluwstein 等人的贡献正是证明：在信贷增长和收益率曲线这两个最强预测因子之上，ML 能学到非线性和交互——比如曲线平坦化在信贷繁荣期比在其他时期危险得多。du Plessis 和 Fritsche 2025 年用 13 种算法在 147 年的系统性危机样本上验证了这个结论的稳健性。

左边这张图是真实数据：Omni Oracle 每天从美国财政部拉取的收益率曲线，算成月均利差。可以看到 2025 年上半年曾短暂倒挂，之后逐步转正，目前在 80 个基点以上。网站宏观页上的「金融危机预警」卡片把七个指标——利差、衰退概率、Sahm 规则、信用利差、VIX、增长、核心通胀——按公开阈值打分，合成一个 0 到 100 的脆弱性指数。请注意措辞：它是脆弱性度量，不是时点信号。

过渡语

从预测经济到预测公司——趋势预测里 AI 的增益来自完全不同的地方。

可能的提问

问：为什么用 10Y-3M 而不是 10Y-2Y？

答：纽约联储的模型用 3 个月期，因为它更直接反映当前政策利率；Estrella 和 Mishkin 的原始研究也发现 3 个月期的预测力更强。两者高度相关，结论通常一致。

问：Sahm 规则现在是什么状态？

答：截至 2026 年 8 月，3 个月平均失业率相对 12 个月低点变化为 -0.07 个百分点，远低于 0.5 的触发阈值。网站上可以实时查看。

资料来源

- Bluwstein, Buckmann, Joseph, Kapadia & Sımsçek (2023), JIE
- du Plessis & Fritsche (2025), Journal of Forecasting
- Estrella & Trubin (2006), NY Fed Current Issues; Sahm (2019)
- 数据：美国财政部每日收益率曲线（Omni Oracle 每日快照）

第 10 页 · 趋势公司与股票：文本嵌入正在成为新的因子

幻灯片要点

- **蓝本** — Gu, Kelly & Xiu (2020, RFS): ML 的增益来自非线性交互；主导信号仍是动量、流动性、波动率。
- **文本进入因子** — 10-K 嵌入沿供应链知识图谱传播 (2606.29290); LLM 过滤语义网络中的伪连边 (2604.19476); 结构化事件抽取而非纯嵌入 (2512.19484)。
- **专利与创新** — Kogan et al. (2017) 市场反应法专利价值；市场对专利文本反应不足 (Zheng 2025 CAR)——可利用的信号。
- **纪律** — Welch–Goyal 式扩展窗口样本外；与 FF5 / q 因子对比；只用评分日前发布的文本。
- **0.86 年化 Sharpe**: 10-K 嵌入 + 供应链传播因子 (2606.29290)
- **7.27% 年 FF5 alpha**, 同一策略, S&P 500 2011–2025
- **x2 Gu–Kelly–Xiu**: 树与神经网络策略表现约为回归的两倍

讲稿

趋势预测和股票排序里，AI 的增益来自两处：非线性，和文本。

非线性的经典证据是 Gu、Kelly 和 Xiu 2020 年在《金融研究评论》的论文：用树模型和神经网络做资产定价，策略表现大约是线性回归的两倍。但他们也很诚实：主导信号仍然是动量、流动性、波动率这些老因子，增益来自因子之间的交互，而不是发现了新因子。

2026 年的新进展是文本进入了因子体系。上面三个数字来自今年六月的一篇论文：把标普 500 公司 10-K 报告的文本嵌入，沿着供应链知识图谱传播，构建的因子在 2011 到 2025 年实现 0.86 的年化夏普比率和每年 7.27% 的五因子 alpha。另一篇论文提醒我们要小心：文本相似不等于经济联系，需要用 LLM 过滤语义网络中的伪连边。还有一条路线是让 LLM 做结构化事件抽取，而不是只用嵌入。

专利是另一条被低估的信号。Kogan 等人用市场反应衡量专利价值，比引用数更能预测公司增长；Zheng 2025 年发现市场对专利文本反应不足——这是一个可利用的信号。

最后是纪律，和第六页完全对应：扩展窗口样本外、与五因子模型对比、只用评分日之前发布的文本。Omni Oracle 的记分卡就是按这个逻辑呈现的：创新分、趋势暴露、机器学习十分位，并明确标注不确定性。

过渡语

所有这些预测——宏观的、危机的、公司的——如果不能被评分，就只是观点。

可能的提问

问：0.86 的夏普在实盘中能保持吗？

答：论文是样本外回测，但没有考虑交易成本和容量，实盘通常打折。我们引用它是为了说明文本信号的方向性价值，而不是作为投资建议。

资料来源

- Gu, Kelly & Xiu (2020), RFS
- arXiv 2606.29290; arXiv 2604.19476; arXiv 2512.19484
- Kogan, Papanikolaou, Seru & Stoffman (2017), QJE; Zheng (2025), CAR

第 11 页 · 能被评分的预测才会进步

幻灯片要点

- **Brier 分与校准曲线** — 对每个预测者、每个模型、每个集成公开记录；校准曲线揭示过度自信。
- **污染安全评分** — AI 参与者只在其知识截止之后创建的问题上计分；UI 上永远显示截止日期徽章。
- **Alpha Score** — arXiv 2605.00420：以提交时的市场中价为基准评分——链上市场是天然的未污染题库。
- **谨慎解读短期 PnL** — 六个前沿模型真钱交易 57 天全部亏损（Prediction Arena）；2026 世界杯 104 场，四个智能体无一打败博彩公司（2607.17765）。真实台账：入账时市场价的 Brier ≈ 0.1 （2026-10，42 道）——要击败的基准，每日更新。

讲稿

没有评分的预测只是观点。这一页讲怎么让所有参与者——人、模型、集成——在同一套尺子下被衡量。

第一是 Brier 分和校准曲线。Brier 分衡量准确率，校准曲线衡量诚实度：你说 70% 的事情，是不是真的有 70% 发生了。大多数人和大多数模型都过度自信，校准曲线会把这一点暴露出来。

第二是污染安全评分。AI 参与者只在其知识截止之后创建的问题上计分，界面上永远显示截止日期徽章。这是第六页那条纪律的产品化。

第三是 Alpha Score，今年五月的一个新指标：以提交时刻的预测市场中价为基准来评分。链上预测市场有一个独特优势——问题是公开创建的、时间戳不可篡改，是天然的未污染题库。

第四条是一个警告。六个前沿模型在 Kalshi 和 Polymarket 上用真钱自主交易 57 天，全部亏损；2026 年世界杯 104 场比赛，四个前沿智能体 92% 的比赛选了同一热门，没有一个打败博彩公司的 Brier 分。这告诉我们两件事：LLM 直接交易还不成熟；以及短期收益排名几乎没有信息量。顺便给一个真实数字：Omni Oracle 的问题台账里，已结算问题上「入账时市场价」的 Brier 大约在 0.1 上下（2026 年 10 月初，42 道已结算）——这就是任何参与者要击败的基准，它每天自动更新，网站首页就能看到。

过渡语

把前面十页压成一张图，就是我们实际搭出来的架构。

可能的提问

问：Brier 分能比较不同难度的问题吗？

答：直接比较不行，所以正规做法是所有参与者回答同一批问题，或者用相对基准（比如相对市场中价）来评分——这正是 Alpha Score 的思路。

资料来源

- arXiv 2605.00420 (Alpha Score)
- arXiv 2605.19337 系列 (LLM 代理真钱交易)
- Tetlock & Gardner (2015), Superforecasting; Gneiting & Raftery (2007) 评分规则

第 12 页 · 一套可以今天开始搭的架构（Omni Oracle 演示实现）

幻灯片要点

- **数据层** — 官方 API（BEA/BLS/世行/财政部）+ 每日快照回退 + 实时价格；每张卡片标注 Live / Cached / Snapshot / Demo
- **模型层** — DFM → 随机森林 → TSFM → BVAR 情景；AR(1) 作为透明基线
- **文本层** — BYOK LLM 分析师：只读取页面上已有的官方序列，输出解读而非数字
- **群体 + 市场层** — 预测锦标赛、Polymarket 实时赔率、LMSR 模拟市场
- **集成 + 评分层** — 按样本外表现加权、归因透明；Brier 排行榜、知识截止徽章、危机预警合成分

讲稿

这是 Omni Oracle 的实际架构，五层，信号自下而上流动。

最底层是数据。这里的重点不是「多」，而是「可信」：只用官方来源——BEA、BLS、世界银行、财政部——加每日快照兜底，加实时价格。每张卡片都标注数据状态：实时、缓存、快照还是演示数据。用户永远知道自己看的是什么。

往上是模型层和文本层，并列。模型层就是第四页的栈：DFM、随机森林、TSFM、BVAR 情景，外加一个 AR(1) 作为透明基线——任何复杂模型都必须先打败它。文本层是自带密钥的 LLM 分析师，它只读取页面上已经加载的官方序列，输出解读，不输出数字。这是第五页原则的落实。

再往上是群体和市场层：预测锦标赛、Polymarket 实时赔率、以及一个用 Hanson LMSR 机制做的模拟市场。它们提供与模型误差不相关的信号。

最顶层是集成和评分：按样本外表现加权、归因透明、Brier 排行榜、知识截止徽章、危机预警合成分。整个平台是纯前端、无后端、无密钥、开源，任何人都可以复现。

过渡语

架构有了，接下来做什么？

可能的提问

问：没有后端怎么保证数据可靠？

答：用 GitHub Actions 每天抓取所有上游 API 并把结果提交到仓库，浏览器优先读这份快照。官方统计一天更新一次足够；价格类数据则实时拉取、快照兜底。

资料来源

- github.com/presleyzhou/omni-oracle — DESIGN.md, RESEARCH-UPDATES.md

第 13 页 · 按「投入 × 影响」排序的七步

幻灯片要点

#	改进项	模块	投入	影响
1	AI 预测者基准 + 人/AI/集成 Brier 对比	C1/C2	中	★★★★★
2	TSFM (Chronos-2) 加入即时预测集成并归因	M1	中	★★★★★
3	AI 交易沙盒 vs LMSR 市场（自带密钥、模拟资金）	P/C5	中	★★★★★
4	M3 交互拓扑 + 历史种子验证	M3	中—大	★★★★★
5	相关市场语义聚类	P	小	★★★★
6	M2 记分卡文本情绪列（时点纪律）	M2	小—中	★★★★
7	全体 AI 参与者的污染安全评分规则	C3	小	★★★（可信度）

讲稿

路线图按投入和影响排序，来自我们对 2025 到 2026 年文献的系统梳理。

前三项都可以在 90 天内以演示形式上线。第一项 AI 预测者基准，直接利用现有的自带密钥管道，让多个模型回答同一批锦标赛问题，与人类同表计分——这是第七页的产品化。第二项把 TSFM 加进即时预测集成，先离线跑、公开实时记录。第三项 AI 交易沙盒，在市场页已经有雏形。

第四项 M3 的交互拓扑是 2026 年多智能体模拟的前沿，投入更大。第五、六项是小投入的信号增强。第七项——污染安全评分规则——影响评级只有三星，但它决定整个平台的可信度，我建议与第一项同时做。每一项在 GitHub 上都有对应的 Issue，欢迎参与。

过渡语

最后，五条原则，一条底线。

资料来源

- Omni Oracle RESEARCH-UPDATES.md §Priority order

第 14 页 · 五条原则，一条底线

幻灯片要点

- 1. 更快的数据 + 更宽的样本 + 更多的视角——对应三种误差来源
- 2. LLM 负责读，计量模型负责算；文本生成特征，不生成预测值
- 3. 集成而非替换：模型 + 群体 + 市场，按样本外表现加权并公开归因
- 4. 时间纪律高于算法：时间戳、数据 vintage、知识截止后计分
- 5. 先规则后模型：危机预警建立在有理论的指标之上
- 底线：LLM 直接做多元数值预测仍弱于线性回归；TSFM 嵌入非平稳；AI 代理真钱交易 57 天全部亏损。AI 提高的是流程的准确性，不是先知的能力。

讲稿

回到开头的三种误差来源，五条原则一一对应。

第一，更快的数据、更宽的样本、更多的视角——分别对应数据滞后、机制切换、先验偏差。第二，LLM 负责读，计量模型负责算；文本生成特征，不生成预测值。第三，集成而非替换：模型、群体、市场三类信号按样本外表现加权，并公开归因。第四，时间纪律高于算法：时间戳、数据 vintage、只在知识截止之后计分。第五，先规则后模型：危机预警建立在有理论的指标之上。

底线是三句话，全部来自今天引用的文献，请原样带走：LLM 直接做多元数值预测仍然弱于线性回归；时序基础模型的内部表示会随机制漂移；AI 代理用真钱交易 57 天全部亏损。

所以我对开头那个问题的回答是：AI 提高的是整个预测流程的准确性和可评分性——更快的数据、更宽的信息面、更诚实的评估——而不是给我们一个先知。谢谢大家。

过渡语

参考文献在下一页，所有 arXiv 编号可直接检索。

可能的提问

问：如果只能做一件事，先做哪件？

答：先做评分。把现有的所有预测——不管来自人、模型还是市场——放到同一套 Brier 分和校准曲线下。没有评分，后面所有改进都无法验证。

问：个人投资者能用上这些吗？

答：网站上的所有功能都是免费、开源、无需注册的。但请注意每一页的免责声明：这是研究原型，所有市场都是模拟资金，不构成投资建议。

资料来源

- 综合本讲全部引用

第 15 页 · 参考文献与数据来源

幻灯片要点

- Stevanovic, D. (2026). Who Saw It Coming? Historical Experience and the 2021 Inflation Forecast Failure. arXiv 2604.14467.
- Giannellis et al. (2026). Inflation Forecasting With Large Language Models. Journal of Forecasting. doi 10.1002/for.70139.
- Alam et al. (2026). ChatMacro: Evaluating Inflation Forecasts of Generative AI. FRB San Francisco WP.
- ECB Blog (2026–04–21). Navigating uncertain times with the help of AI. Lenza et al. (2025), EER 178.
- JKSU–CIS (2026). LLMs for unstructured economic data processing: GDP forecasting. doi 10.1007/s44443–026–00788–2.
- Kant, Pick & Winter (2024), AStA; IMF WP/2025/252 — ML nowcasting horseraces.
- Chronos–2 (Amazon, 2025–10); TimesFM 2.5 (Google); MDPI MAKE 7(4):135 — RBNZ TSFM 比较; arXiv 2604.16428; 2511.18578.
- ForecastBench (Wharton, 2026–02; arXiv 2409.19839); Lu (2025) arXiv 2507.04562; Phil. Trans. R. Soc. B 381 (2026).
- Look–Ahead–Bench arXiv 2601.13770; Profit Mirage 2510.07920; Chronologically Consistent LLMs 2502.21206; Agentic Time Machine 2606.21013; MACROCAST 2606.28670.
- Bluwstein, Buckmann, Joseph, Kapadia & Sımsık (2023), JIE; du Plessis & Fritsche (2025), J. Forecasting; Estrella & Trubin (2006); Sahm (2019).
- Gu, Kelly & Xiu (2020), RFS; arXiv 2606.29290; 2604.19476; 2512.19484; Kogan et al. (2017), QJE.
- Alpha Score arXiv 2605.00420; Prediction Arena arXiv 2604.07355; WC2026–Agents arXiv 2607.17765; Multi–agent oracles arXiv 2605.30802.
- Timmermann (2006); Ranjan & Gneiting (2010); Gneiting & Raftery (2007).
- Omni Oracle: github.com/presleyzhou/omni-oracle — DESIGN.md, RESEARCH–UPDATES.md, data/live.json.

讲稿

参考文献页，无需讲述。所有 arXiv 编号可直接在 arxiv.org 检索；ECB 博客与 ForecastBench 排行榜为公开网页；数据来源均为官方或交易所公开 API，由 Omni Oracle 的每日快照 workflow 刷新。